

Como a situação socioeconômica dos participantes está relacionada ao desempenho obtido nas provas de ENEM?

Grupo - Enem

6 de outubro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Teoria do Aprendizado Estatístico | Prof. Dr. João
Paulo Ferreira de Mello

Ana Luiza Bispo Aguiar – RA 0051352511020

Caio Kenji de Paula Maeshiro – RA 0051352511008

Lucas Murinelly Feliciano – RA 0051352511013

Pedro Santos Malaquias Rodrigues – RA 00513525110041

Repositório: TAE-ENEM

1 Introdução

O Exame Nacional do Ensino Médio (ENEM) é uma avaliação educacional importante no Brasil e seus resultados são utilizados em diferentes processos para facilitar o acesso dos estudantes ao ensino superior. O desempenho dos participantes pode estar relacionado a diversos fatores, entre eles as condições socioeconômicas, familiares e educacionais. O objetivo desta pesquisa está relacionado as possíveis desigualdades de condições entre os participantes.

Fatores como renda familiar, escolaridade dos responsáveis e acesso à internet podem impactar em condições diferentes de preparação para o exame. Dessa forma, é importante analisar os dados para verificar se essas características apresentam alguma relação com as notas dos participantes.

A pesquisa busca responder à seguinte pergunta: como a situação socioeconômica dos participantes está relacionada ao desempenho obtido nas provas de ENEM? O objetivo

geral é analisar a relação entre as características socioeconômicas dos participantes e seu desempenho no exame, utilizando dados públicos para identificar os possíveis padrões e as diferenças nos resultados.

O artigo será organizado em seções que apresentam inicialmente os procedimentos utilizados na coleta e análise dos dados. Por fim, serão apresentados os resultados e a defesa da pergunta.

2 O banco de dados e o problema

O banco de dados utilizado foi construído a partir dos microdados do ENEM, disponibilizados pelo INEP, com informações das edições de 2021 a 2025 (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2026).

Cada linha do banco representa um participante do ENEM. Para medir o desempenho, foi criada a variável **MEDIA**, calculada a partir da média das cinco notas das provas: Ciências da Natureza, Ciências Humanas, Linguagens, Matemática e Redação.

Também foram escolhidas duas informações socioeconômicas: renda familiar (Q007) e a raça dos alunos (TPCORRACA).

O objetivo do trabalho é analisar se essas condições socioeconômicas estão relacionadas ao desempenho dos participantes no ENEM.

3 A pergunta

A pergunta deste trabalho é: **Como as condições socioeconômicas dos participantes estão relacionadas ao desempenho obtido no ENEM?**

Tabela 1 – Ficha da pergunta

Campo	Preenchimento
1. Pergunta	Relação entre situação socioeconômica e média das notas do ENEM.
2. Resposta Y	MEDIA , quantitativa contínua, de 0 a 1000 pontos; média das cinco notas.
3. Preditores X	TP_COR_RACA se tornou uma variável categórica nominal chamada RACA .
4. Tipo	Aprendizado supervisionado; regressão; foco inicial em predição, com interpretação descritiva das associações.
5. Métrica	RMSE, em pontos da escala de Y .
6. Linha de base	Prever sempre a média de Y : $RMSE \approx 88.93$ pontos.
7. Dono do problema	Equipes de gestão e planejamento educacional, interessadas em identificar padrões associados ao desempenho e apoiar estudos sobre desigualdades educacionais.

Fonte: Elaborada pelos autores.

Escolhemos a regressão porque queremos prever uma nota, que é uma variável quantitativa. O objetivo é usar as informações socioeconômicas para prever a média do ENEM.

4 Defesa da pergunta

A Tabela 2 reúne as quatro verificações feitas sobre o banco.

Tabela 2 – Diagnóstico do banco

Verificação	Resultado
Tamanho ($n \times p$)	35471×14
Linha de base	acurácia = 0,622 (chutar a classe mais comum)
Maior correlação com Y	não se aplica (resposta qualitativa)
Balanco das classes	FALSE: 22063 TRUE: 13408
Valores faltantes	nenhum

Fonte: Elaborada pelos autores.


Vazamento. Como a variável resposta **RACA** é qualitativa, a correlação não foi utilizada para diagnosticar vazamento. Foi analisado se o único preditor, **MEDIA**, separava quase perfeitamente as duas classes. As distribuições apresentaram forte sobreposição: a mediana da **MEDIA** foi 557,4 para **RACA** = FALSE que significa que o estudante não pertence a uma raça socialmente afetada e 533,3 para **RACA** = TRUE, que significa que o estudante pertence a uma raça socialmente afetada, com intervalos de 146,74 a 836,06 e de 0 a 823,56, respectivamente. A AUC obtida foi 0,567, indicando baixa capacidade de discriminação. Assim, **MEDIA** não contém nem reproduz praticamente a resposta, não havendo evidência de vazamento de informação. Nenhuma variável precisou ser removida por esse motivo.

Tamanho. São 35471 observações para 14 preditores. Comente se há observações suficientes por coluna, e o que isso implica para a escolha do modelo.

Balanco e faltantes. Comente o balanço das classes (quando a resposta for qualitativa) e a presença de valores faltantes, dizendo o que o grupo pretende fazer com eles.

A Figura 1 mostra a distribuição da resposta.

Figura 1 – Distribuição da resposta RACA



Fonte: Elaborada pelos autores.

Veredito. A pergunta se sustenta de forma provisória, pois as verificações realizadas até o momento não indicaram problemas que inviabilizem a análise. Não foi encontrada evidência de vazamento de informação, já que a variável utilizada não separa de forma quase perfeita os grupos analisados. Dessa forma, a pergunta pode ser mantida nesta etapa do trabalho. Nas próximas aulas, com a aplicação completa dos métodos de aprendizado supervisionado, será possível avaliar melhor a capacidade preditiva das variáveis socioeconômicas e verificar se será necessário ajustar a pergunta ou a escolha dos preditores.

Referências

Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. *Microdados do ENEM*. 2026. Disponível em: <<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enem>>. Acesso em: 2 out. 2026.

(Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2026)